



Московский государственный университет имени М.В.Ломоносова
Факультет вычислительной математики и кибернетики
Кафедра математической статистики

Вагапова Деши Насрудиновна

Методы обработки и классификации нестационарных биосигналов с использованием машинного обучения

Курсовая работа

Научный руководитель:
к.ф.-м.н.
Захарова Татьяна Валерьевна

Москва, 2026

Аннотация

Методы обработки и классификации нестационарных биосигналов с использованием машинного обучения

Вагапова Деши Насрудиновна

В работе исследуются методы автоматической классификации нестационарных биосигналов — электрокардиограмм (ЭКГ) — с использованием алгоритмов машинного обучения. На основе базы данных MIT-BIH Arrhythmia Database, содержащей более 100 000 размеченных сердечных биений пяти классов аритмий (норма, предсердная экстрасистола, желудочковая экстрасистола, блокада левой и правой ножек пучка Гиса), реализованы и сравниваются три модели: случайный лес (Random Forest), одномерная сверточная нейронная сеть (1D CNN) и остаточная нейронная сеть (ResNet1D). Для борьбы с дисбалансом классов применяется взвешенная функция потерь. Проведена оценка устойчивости моделей к четырем типам реалистичных помех: гауссовому шуму, дрейфу изолинии, сетевой помехе 50 Гц и мышечному шуму. Достоверность результатов подтверждена пятикратной стратифицированной кросс-валидацией. Показано, что 1D CNN превосходит конкурентов по качеству классификации на чистых данных (Macro F1 = 0.974) и устойчива к медленным трендам и мышечному шуму, тогда как случайный лес обеспечивает наилучшую воспроизводимость результатов и стойкость к случайным аддитивным помехам.

Abstract

Methods for Processing and Classification
of Non-Stationary Biosignals Using Machine Learning

This work investigates methods for automatic classification of non-stationary biosignals — electrocardiograms (ECG) — using machine learning algorithms. Based on the MIT-BIH Arrhythmia Database containing over 100,000 annotated heartbeats across five arrhythmia classes (normal, atrial premature contraction, ventricular premature contraction, left and right bundle branch block), three models are implemented and compared: Random Forest, one-dimensional Convolutional Neural Network (1D CNN), and Residual Neural Network (ResNet1D). A weighted loss function is applied to address class imbalance. The robustness of the models is evaluated against four types of realistic noise: Gaussian noise, baseline wander, 50 Hz powerline interference, and muscle (EMG) noise. Five-fold stratified cross-validation is performed to confirm reliability. It is shown that 1D CNN achieves the best classification quality on clean data (Macro F1 = 0.974) and is robust to baseline wander and muscle noise, while Random Forest provides the best reproducibility and resistance to random additive noise.

Содержание

Список сокращений	6
1 Введение	7
2 Постановка задачи и описание данных	9
2.1 Формальная постановка задачи	9
2.2 Описание данных	9
2.2.1 База данных MIT-BIH Arrhythmia Database	9
2.2.2 Классы аритмий	9
2.2.3 Предобработка: извлечение кардиоциклов	10
2.2.4 Нормализация	10
2.3 Разбиение на выборки	11
2.4 Проблема дисбаланса классов и способы ее решения	12
2.5 Требования к решению	12
3 Методы классификации биосигналов	14
3.1 Случайный лес	14
3.1.1 Алгоритм	14
3.1.2 Настройка гиперпараметров	14
3.1.3 Важность признаков	14
3.2 Одномерная сверточная нейронная сеть (1D CNN)	15
3.2.1 Мотивация	15
3.2.2 Архитектура	15
3.2.3 Обучение	15
3.3 Остаточная нейронная сеть (ResNet1D)	15
3.3.1 Мотивация и остаточное соединение	15
3.3.2 Архитектура	17
3.3.3 Обучение	17
3.4 Вейвлет-анализ ЭКГ-сигналов	18
3.4.1 Ограничения преобразования Фурье	18
3.4.2 Дискретное вейвлет-преобразование	18
3.4.3 Вейвлет-признаки для случайного леса	18

3.5	Сравнительный анализ методов	20
4	Результаты классификации на чистых данных	21
4.1	Сводная таблица метрик	21
4.2	Анализ по классам: матрицы ошибок	21
4.2.1	1D CNN	21
4.2.2	ResNet1D	22
4.2.3	Random Forest	22
4.2.4	Сравнение по классу А	23
4.3	Кривые обучения нейронных сетей	24
4.3.1	1D CNN	24
4.3.2	ResNet1D	25
4.4	Важность признаков Random Forest	25
4.5	Эксперимент с вейвлет-признаками	25
5	Устойчивость к шуму и кросс-валидация	28
5.1	Модели артефактов ЭКГ-сигналов	28
5.2	Результаты экспериментов с шумом	29
5.2.1	Гауссов шум	29
5.2.2	Дрейф изолинии	29
5.2.3	Сетевая помеха 50 Гц	30
5.2.4	Мышечный шум	31
5.2.5	Обобщенное сравнение устойчивости	31
5.3	Кросс-валидация	32
5.3.1	Методология	32
5.3.2	Результаты по фолдам	32
5.3.3	Сводные оценки	33
5.3.4	Интерпретация	33
5.4	Сопоставление с требованиями постановки задачи	34
6	Заключение	37
	Список литературы	40

Список сокращений

ЭКГ — электрокардиограмма

ВОЗ — Всемирная организация здравоохранения

МО — машинное обучение

СЛ — случайный лес (Random Forest, RF)

СНС — сверточная нейронная сеть (Convolutional Neural Network, CNN)

ResNet — остаточная нейронная сеть (Residual Network)

ДВП — дискретное вейвлет-преобразование

НВП — непрерывное вейвлет-преобразование

БЛНПГ — блокада левой ножки пучка Гиса

БПНПГ — блокада правой ножки пучка Гиса

ЖЭ — желудочковая экстрасистола

ПЭ — предсердная экстрасистола

ЭМГ — электромиограмма (мышечный шум)

MDI — средний прирост информации (Mean Decrease in Impurity)

F1 — F1-мера (гармоническое среднее точности и полноты)

Macro F1 — макро-усреднённая F1-мера

MIT-BIH — база данных аритмий Массачусетского технологического института и Бет-Израэль больницы

1 Введение

Сердечно-сосудистые заболевания занимают первое место среди причин смертности в мире: по данным Всемирной организации здравоохранения, ежегодно от них погибает более 17 миллионов человек [1]. Значительную долю среди них составляют нарушения сердечного ритма — аритмии, которые нередко протекают бессимптомно, но при отсутствии своевременной диагностики могут приводить к инфаркту миокарда, инсульту или внезапной остановке сердца. Главным инструментом выявления аритмий является электрокардиограмма (ЭКГ) — запись электрической активности сердца во времени.

При суточном холтеровском мониторинге за 24 часа регистрируется от 80 000 до 120 000 сердечных сокращений. Ручной разбор такой записи квалифицированным кардиологом требует многих часов работы и неизбежно сопровождается усталостными ошибками. Именно поэтому автоматическая классификация ЭКГ-сигналов средствами машинного обучения представляет большой практический интерес: она позволяет ускорить диагностику и снизить риск пропуска опасных состояний.

Особую сложность представляет *нестационарность* ЭКГ-сигнала — его амплитуда, форма и ритм меняются со временем под влиянием физической нагрузки, дыхания и эмоционального состояния пациента. Классические методы спектрального анализа Фурье, рассчитанные на стационарные сигналы, не позволяют в полной мере описать такую изменчивость. Более гибким инструментом в данном случае является вейвлет-преобразование, которое одновременно учитывает частотный состав сигнала и момент его возникновения во времени [2].

За последние годы глубокое обучение существенно продвинулось в задаче распознавания аритмий: сверточные и остаточные нейронные сети достигают точности, сопоставимой с экспертом-кардиологом [3]. Тем не менее традиционные методы — в первую очередь случайный лес — по-прежнему остаются востребованными благодаря высокой интерпретируемости и устойчивости к помехам, что особенно ценно в клинической практике, где надежность и объяснимость модели не менее важны, чем метрики точности.

Настоящая работа посвящена сравнению трех подходов к автоматической классификации кардиоциклов (нормы и четырех типов аритмий) на базе данных MIT-BIH Arrhythmia Database: случайного леса, одномерной сверточной нейронной сети и остаточной нейронной сети. Помимо классификации на чистых данных, исследуется устой-

чивость моделей к четырем видам реалистичных помех — гауссову шуму, дрейфу изолинии, сетевой помехе 50 Гц и мышечному шуму — а также проводится частотно-временной анализ сигналов с помощью дискретного вейвлет-преобразования.

Работа состоит из пяти разделов. В разделе 2 формализуется постановка задачи и описываются данные и конвейер предобработки. Раздел 3 посвящен теоретическому описанию моделей и методам вейвлет-анализа. В разделе 4 приводятся результаты классификации на чистых данных. Раздел 5 содержит анализ устойчивости к шуму и результаты кросс-валидации. В заключении (6) формулируются выводы и направления дальнейших исследований.

2 Постановка задачи и описание данных

2.1 Формальная постановка задачи

Пусть задана выборка $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, где $\mathbf{x}_i \in \mathbb{R}^d$ — вектор признаков i -го кардиоцикла, $y_i \in \mathcal{Y} = \{N, A, V, L, R\}$ — его класс, $N = 100\,025$ — общее число объектов, $d = 240$ — размерность пространства признаков.

Задача классификации. Требуется построить функцию $f: \mathbb{R}^d \rightarrow \mathcal{Y}$, минимизирующую макроусредненную ошибку классификации по всем классам:

$$\text{Macro F1} = \frac{1}{|\mathcal{Y}|} \sum_{k \in \mathcal{Y}} \frac{2 \text{TP}_k}{2 \text{TP}_k + \text{FP}_k + \text{FN}_k}, \quad (1)$$

где TP_k , FP_k , FN_k — число истинно положительных, ложно положительных и ложно отрицательных срабатываний модели для класса k соответственно.

Метрика Macro F1 выбрана основной, поскольку она одинаково взвешивает все классы независимо от их частоты в выборке — что принципиально важно при сильном дисбалансе (класс A составляет лишь 2.5 % выборки). Дополнительно отслеживаются Accuracy и Weighted F1.

2.2 Описание данных

2.2.1 База данных MIT-BIH Arrhythmia Database

В работе используется открытая база MIT-BIH Arrhythmia Database [4, 5] — международный стандарт для оценки алгоритмов обнаружения аритмий [6]. База содержит 48 двухканальных записей ЭКГ по 30 минут каждая, оцифрованных с частотой дискретизации $f_s = 360$ Гц при разрядности 11 бит (± 5 мВ в диапазоне). Каждое сердечное сокращение размечено двумя независимыми кардиологами-экспертами.

2.2.2 Классы аритмий

Из полного набора символов аннотаций выбраны 5 клинически значимых классов, охватывающих наиболее распространенные нарушения ритма (таблица 1).

Класс N существенно преобладает — соотношение «норма : предсердная экстрасистола» составляет $\approx 30:1$. Такой дисбаланс классов является типичной проблемой ме-

Таблица 1: Распределение классов в итоговой выборке

Символ	Клиническое название	Число ударов	Доля, %	Отношение к N
N	Норма	75 023	75.0	1:1
L	Блокада левой ножки пучка Гиса	8 075	8.1	1:9.3
R	Блокада правой ножки пучка Гиса	7 259	7.3	1:10.3
V	Желудочковая экстрасистола	7 129	7.1	1:10.5
A	Предсердная экстрасистола	2 539	2.5	1:29.6
Итого		100 025	100	—

дицинских данных и требует специальных мер как при обучении моделей, так и при выборе метрики качества.

2.2.3 Преобработка: извлечение кардиоциклов

Каждый кардиоцикл вырезается из записи в виде окна фиксированного размера $d = 240$ отсчетов с центром в R-пике — точке максимальной амплитуды комплекса QRS (рисунок 1):

$$\mathbf{x}_i = (s[r_i - 100], s[r_i - 99], \dots, s[r_i + 139]) \in \mathbb{R}^{240}, \quad (2)$$

где $s[\cdot]$ — отсчеты сигнала ЭКГ, r_i — позиция R-пика i -го удара из аннотации базы данных. Выбор асимметричного окна $100 + 140$ обусловлен тем, что зубец P расположен непосредственно перед QRS, тогда как зубец T после него — более протяженный. При $f_s = 360$ Гц окно длиной 240 отсчетов соответствует ≈ 667 мс, что достаточно для фиксации полного кардиоцикла при частоте пульса до ≈ 90 уд/мин. Удары, для которых окно выходит за границы записи, исключаются.

2.2.4 Нормализация

Для нейронных сетей каждый признак нормализуется по обучающей выборке с помощью стандартного масштабирования:

$$\tilde{x}_{ij} = \frac{x_{ij} - \hat{\mu}_j}{\hat{\sigma}_j}, \quad j = 1, \dots, d, \quad (3)$$

где $\hat{\mu}_j$ и $\hat{\sigma}_j$ — выборочные среднее и стандартное отклонение j -го признака по обучающей выборке. Параметры нормализации вычисляются исключительно на обучающих




Рис. 1: Вейвлет-разложение нормального кардиоцикла (класс N): исходный сигнал и уровни ДВП db4. По оси абсцисс — номер отсчета; по оси ординат — амплитуда в мВ.

данных и применяются к тестовой выборке без повторной подгонки — во избежание «утечки» информации из теста. Для случайного леса нормализация не требуется, поскольку деревья решений инвариантны к монотонным преобразованиям признаков.

2.3 Разбиение на выборки

Выборка разбивается на обучающую (80 %) и тестовую (20 %) части методом стратифицированного разбиения:

$$|\mathcal{D}_{\text{train}}| = 80\,020, \quad |\mathcal{D}_{\text{test}}| = 20\,005. \quad (4)$$

Стратификация гарантирует, что доля каждого класса в обеих частях совпадает с долей в исходной выборке. Фиксированный начальный номер генератора случайных чисел (`random_state=42`) обеспечивает воспроизводимость результатов.

Для оценки стабильности моделей дополнительно проводится пятикратная стратифицированная кросс-валидация (см. раздел 5).

2.4 Проблема дисбаланса классов и способы ее решения

Сильный дисбаланс классов — в первую очередь малочисленность класса А — порождает систематическое смещение модели в пользу большинства: модель, предсказывающая «норму» для всех объектов, достигает Ассигасу $\approx 75\%$, оставаясь при этом клинически бесполезной.

В данной работе применяются два независимых механизма компенсации дисбаланса:

1. **Взвешенная функция потерь** для нейронных сетей. Каждому классу k назначается вес, обратно пропорциональный его частоте в обучающей выборке:

$$w_k = \frac{1/n_k}{\sum_{j \in \mathcal{Y}} 1/n_j} \cdot |\mathcal{Y}|, \quad (5)$$

где n_k — число объектов класса k в обучающей части. Взвешенная кросс-энтропия:

$$\mathcal{L} = - \sum_{k \in \mathcal{Y}} w_k \sum_{i: y_i=k} \log \hat{p}_{ik}, \quad (6)$$

где $\hat{p}_{ik}$ — предсказанная вероятность класса k для объекта i .

2. **Стратегия `balanced_subsample`** для случайного леса: при построении каждого дерева обучающая выборка для бутстрэпа ресамплируется с равномерным представлением всех классов.

2.5 Требования к решению

По итогам работы решение должно удовлетворять следующим требованиям:

- Macro F1 не ниже 0.90 на тестовой выборке для каждой из трех моделей.
- Recall класса А (предсердная экстрасистола) не ниже 0.65 — клинически значимое нарушение не должно систематически пропускаться.

- Стандартное отклонение Macro F1 по фолдам кросс-валидации не выше 0.03 — требование к стабильности модели.
- Модели должны быть сохранены в воспроизводимом формате для последующего применения на новых записях.

3 Методы классификации биосигналов

В данном разделе описываются три модели машинного обучения, реализованные в работе, а также метод вейвлет-анализа, применявшийся для частотно-временного исследования ЭКГ-сигналов.

3.1 Случайный лес

3.1.1 Алгоритм

Случайный лес (Random Forest) [7] — ансамблевый метод, основанный на бэггинге над деревьями решений. Для задачи классификации с T деревьями ответ модели определяется голосованием большинства:

$$\hat{y} = \arg \max_{k \in \mathcal{Y}} \sum_{t=1}^T \mathbf{1}[h_t(\mathbf{x}) = k], \quad (7)$$

где $h_t(\mathbf{x})$ — предсказание t -го дерева.

Каждое дерево обучается на бутстрэп-выборке из обучающих данных, а при выборе оптимального разбиения в каждом узле рассматривается случайное подмножество $m \approx \sqrt{d}$ признаков. Такая рандомизация снижает корреляцию между деревьями и уменьшает дисперсию ансамбля [7].

3.1.2 Настройка гиперпараметров

В работе используется $T = 200$ деревьев. Для компенсации дисбаланса классов применяется стратегия `balanced_subsample`: при формировании каждого бутстрэп-экземпляра производится стратифицированная ресамплировка, обеспечивающая равное число объектов каждого класса в обучающей порции дерева. Функционал информативности узла — критерий Джини.

3.1.3 Важность признаков

Случайный лес позволяет оценить вклад каждого признака j в качество классификации через среднее уменьшение примеси (MDI):

$$\text{Imp}(j) = \frac{1}{T} \sum_{t=1}^T \sum_{\text{узлы с разб. по } j} \Delta \text{Gini}_t \cdot \frac{n_{\text{узел}}}{n}, \quad (8)$$

где ΔGini_t — уменьшение индекса Джини в узле. Анализ важности признаков позволяет интерпретировать, какие временные участки кардиоцикла наиболее информативны при разделении классов.

3.2 Одномерная сверточная нейронная сеть (1D CNN)

3.2.1 Мотивация

Сверточные нейронные сети [8] обладают свойством *трансляционной инвариантности*: один и тот же паттерн формы QRS-комплекса обнаруживается вне зависимости от его положения в окне. Применение одномерных сверток к временному ряду ЭКГ позволяет автоматически извлекать иерархические признаки: от низкоуровневых перепадов амплитуды до высокоуровневых форм зубцов.

3.2.2 Архитектура

Входной тензор имеет форму (batch, 1, 240) — один канал, 240 временных отсчетов. Сеть состоит из *сверточного* блока и *классификатора* (таблица 2).

Три стадии свертки с попарным пулингом уменьшают длину временного ряда с 240 до 30 отсчетов, одновременно увеличивая число карт признаков с 1 до 64. Регуляризация достигается через BatchNorm после каждой свертки и Dropout ($p = 0.3$) перед выходным слоем.

3.2.3 Обучение

Оптимизатор — Adam [9] с начальной скоростью обучения $\eta_0 = 10^{-3}$. Планировщик ReduceLROnPlateau снижает η вдвое, если Macro F1 на валидации не улучшается в течение 3 эпох: $\eta \leftarrow 0.5 \eta$. Ранняя остановка с patience = 5 предотвращает переобучение. Число эпох — не более 20; наилучшие веса по Macro F1 сохраняются отдельно.

3.3 Остаточная нейронная сеть (ResNet1D)

3.3.1 Мотивация и остаточное соединение

При увеличении глубины нейронной сети возникает проблема затухающих градиентов: сигнал ошибки, распространяясь в обратном направлении, многократно умно-

Таблица 2: Архитектура 1D CNN

Слой	Параметры	Выход ($C \times L$)	Параметры, шт.
Conv1d	$1 \rightarrow 16, k = 7, p = 3$	16×240	128
BatchNorm1d	16	16×240	32
ReLU	—	16×240	0
MaxPool1d	$k = 2$	16×120	0
Conv1d	$16 \rightarrow 32, k = 5, p = 2$	32×120	2 592
BatchNorm1d	32	32×120	64
ReLU	—	32×120	0
MaxPool1d	$k = 2$	32×60	0
Conv1d	$32 \rightarrow 64, k = 5, p = 2$	64×60	10 304
BatchNorm1d	64	64×60	128
ReLU	—	64×60	0
MaxPool1d	$k = 2$	64×30	0
Flatten	—	1920	0
Linear	$1920 \rightarrow 128$	128	245 888
ReLU	—	128	0
Dropout	$p = 0.3$	128	0
Linear	$128 \rightarrow 5$	5	645
Итого обучаемых параметров			259 781

жаются на небольшие числа и «исчезают» в ранних слоях [10]. Не и др. [11] предложили архитектуру с *остаточными соединениями* (skip connections), вычисляющую не прямое отображение $H(\mathbf{x})$, а остаток $F(\mathbf{x})$:

$$\mathbf{y} = F(\mathbf{x}, \{W_i\}) + \mathbf{x}, \quad (9)$$

где $F(\mathbf{x})$ — нелинейное преобразование двух сверточных слоев, а $\mathbf{x}$ — прямая «шунтирующая» ветвь. Такое соединение устраняет проблему затухания и позволяет обучать существенно более глубокие сети.

3.3.2 Архитектура

Реализованная модель ResNet1D состоит из начального стволового слоя (*stem*) и трех остаточных блоков (таблица 3).

Таблица 3: Архитектура ResNet1D

Блок	Состав	Выход ($C \times L$)	stride
Stem	Conv1d($1 \rightarrow 16, k = 7$) + BN + ReLU	16×240	1
Layer 1	ResidualBlock($16 \rightarrow 16, k = 7$)	16×240	1
Layer 2	ResidualBlock($16 \rightarrow 32, k = 7$)	32×120	2
Layer 3	ResidualBlock($32 \rightarrow 64, k = 7$)	64×60	2
Pool	AdaptiveAvgPool1d(1)	64×1	—
FC	Linear($64 \rightarrow 5$)	5	—

Каждый *ResidualBlock* содержит две последовательные свертки с BatchNorm и ReLU, а также адаптивный шунт: если размерности входа и выхода не совпадают (по каналам или длине), шунт реализуется сверткой 1×1 со stride; иначе — тождественным отображением (Identity). После сложения $F(\mathbf{x}) + \text{shortcut}(\mathbf{x})$ применяется ReLU.

Слой `AdaptiveAvgPool1d(1)` глобально усредняет карту признаков по временному измерению, что делает сеть нечувствительной к его абсолютной длине. Итоговый вектор из 64 нейронов подается в линейный классификатор.

3.3.3 Обучение

Конфигурация обучения аналогична CNN: оптимизатор Adam ($\eta_0 = 10^{-3}$), взвешенная кросс-энтропия (формулы (5), (6)), ReduceLROnPlateau ($\times 0.5$, $\text{patience} = 3$), ранняя остановка ($\text{patience} = 7$), не более 30 эпох. Перед обучением признаки нормализуются по формуле (3), параметры нормализации сохраняются для последующей оценки.

3.4 Вейвлет-анализ ЭКГ-сигналов

3.4.1 Ограничения преобразования Фурье

Классическое преобразование Фурье дает полную информацию о частотном составе сигнала, но не позволяет установить, *в какой момент времени* та или иная частота присутствует. Поскольку ЭКГ является нестационарным сигналом — его характеристики меняются на протяжении одного кардиоцикла (зубцы P, QRS, T имеют различные частотные составы) — для его анализа требуется инструмент совместного частотно-временного представления [2].

3.4.2 Дискретное вейвлет-преобразование

Дискретное вейвлет-преобразование (ДВП) разлагает сигнал $s[n]$ по ортонормированному базису масштабирующих функций и вейвлетов методом пирамидального алгоритма Малла [12]. На каждом уровне разложения j сигнал пропускается через пару фильтров: фильтр нижних частот дает коэффициенты приближения $\{a_j[n]\}$, фильтр верхних частот — коэффициенты детализации $\{d_j[n]\}$:

$$a_j[n] = \sum_k h[k] a_{j-1}[2n - k], \quad d_j[n] = \sum_k g[k] a_{j-1}[2n - k], \quad (10)$$

где $h[k]$ и $g[k]$ — коэффициенты квадратурных зеркальных фильтров, определяемых выбором вейвлета.

В работе используется вейвлет Добеши 4 (db4), обладающий 4 нулевыми моментами — что обеспечивает компактную запись гладких сигналов — и хорошо согласованный с формой QRS-комплекса [2]. При $L = 4$ уровнях разложения и частоте дискретизации $f_s = 360$ Гц формируются следующие частотные подполосы (таблица 4).

3.4.3 Вейвлет-признаки для случайного леса

Для расширения векторного представления каждого кардиоцикла из коэффициентов каждой подполосы cX_j извлекаются 5 статистических признаков:

$$\phi(cX_j) = (\bar{c}_j, \sigma_j, E_j, \max |cX_j|, \gamma_{1,j}), \quad (11)$$

где $\bar{c}_j$ — среднее, σ_j — стандартное отклонение, $E_j = \text{mean}(cX_j^2)$ — энергия, $\gamma_{1,j}$ — коэффициент асимметрии. Таким образом, каждый удар дополнительно описывается вектором из $5 \times 5 = 25$ вейвлет-признаков.

Таблица 4: Частотные подполосы ДВП db4 при $f_s = 360$ Гц

Подполоса	Частоты, Гц	Физ. смысл для ЭКГ	Число коэф.
cD ₁	90–180	Высокочастотный шум (ЭМГ)	≈ 120
cD ₂	45–90	Высокочаст. компоненты QRS	≈ 60
cD ₃	22.5–45	Комплекс QRS	≈ 30
cD ₄	11–22.5	Зубцы Р и Т	≈ 15
cA ₄	0–11	Изолиния, дрейф	≈ 15

В проведенном эксперименте (раздел 4) добавление вейвлет-признаков к 240 временным отсчетам не улучшило качество случайного леса: Macro F1 = 0.9479 (с вейвлетом) против 0.9496 (без него). Это объясняется тем, что ансамбль деревьев неявно обнаруживает частотно-временные паттерны непосредственно из временного ряда, тогда как агрегатные статистики коэффициентов теряют позиционную информацию. Тем не менее вейвлет-анализ представляет значительную ценность для *интерпретации* сигналов: скаллограммы (рисунок 2) и распределение энергии по подполосам (рисунок 3) наглядно демонстрируют, как различные классы аритмий отличаются в частотно-временном пространстве.




Рис. 2: Скаллограммы CWT (вейвлет Морле) для медианного удара каждого класса. Верхний ряд — временной сигнал, нижний — частотно-временное распределение энергии.




Рис. 3: Средняя энергия коэффициентов ДВП db4 по частотным подполосам и классам. Различие классов V и A в подполосах cD₃–cD₄ отражает разницу в форме QRS-комплекса.

3.5 Сравнительный анализ методов

Три рассматриваемые модели занимают различные позиции в пространстве «точность — интерпретируемость — устойчивость» (таблица 5).

Таблица 5: Качественное сравнение моделей

Критерий	RF	1D CNN	ResNet1D
Интерпретируемость	Высокая	Низкая	Низкая
Нормализация	Не нужна	Нужна	Нужна
Устойчивость к шуму	Высокая	Средняя	Средняя
Гиперпараметров	Мало	Умеренно	Много
Время обучения	Быстро	Умеренно	Медленно
Качество (Macro F1)	0.950	0.974	0.953

Случайный лес выигрывает по простоте настройки и интерпретируемости. 1D CNN достигает наилучшего качества классификации за счет автоматического извлечения признаков. ResNet1D потенциально мощнее, но требует большего числа эпох для сходимости и чувствителен к инициализации.

4 Результаты классификации на чистых данных

В данном разделе приводятся результаты обучения и тестирования трех моделей на исходных, незашумленных данных. Все эксперименты воспроизводимы: фиксированы начальный номер генератора случайных чисел (`random_state=42`), разбиение на выборки и гиперпараметры.

4.1 Сводная таблица метрик

Результаты на тестовой выборке ($|\mathcal{D}_{\text{test}}| = 20\,005$) представлены в таблице 6.

Таблица 6: Метрики качества моделей на чистых данных

Модель	Accuracy	Macro F1	Weighted F1
1D CNN	0.9917	0.9736	0.9918
ResNet1D	0.9847	0.9532	0.9848
RandomForest	0.9848	0.9496	0.9841

Все три модели превышают порог $\text{Macro F1} \geq 0.90$, поставленный в разделе 2. Наилучший результат демонстрирует 1D CNN ($\text{Macro F1} = 0.974$), опережая ResNet1D на 0.020 и Random Forest на 0.024. Несмотря на то что Accuracy у RF и ResNet1D практически одинакова (0.9848 против 0.9847), Macro F1 у ResNet1D выше (0.9532 против 0.9496) за счет лучшей работы с миноритарными классами.

4.2 Анализ по классам: матрицы ошибок

4.2.1 1D CNN

CNN добивается $\text{recall} = 0.92$ для класса A — наилучший результат среди всех трех моделей. Это достигается благодаря взвешенной функции потерь (формула (6)), которая увеличивает штраф за пропуск редких классов. Классы N, L, R распознаются практически безошибочно ($\text{recall} \geq 0.98$), класс V — с $\text{recall} \approx 0.97$.




Рис. 4: Нормализованная матрица ошибок 1D CNN. По диагонали — доля правильно классифицированных объектов каждого класса.

4.2.2 ResNet1D

ResNet1D устойчиво классифицирует классы N, L, R, V ($\text{recall} \geq 0.94$). Класс A вызывает наибольшие затруднения: recall несколько ниже, чем у CNN, что объясняется меньшим числом эпох обучения и более сложной архитектурой, требующей большего времени сходимости.

4.2.3 Random Forest

Главная слабость RF — recall класса A = 0.70: каждый третий случай предсердной экстрасистолы пропускается. Это существенный недостаток с клинической точки зрения. Стратегия `balanced_subsample` частично компенсирует дисбаланс, однако не дает того эффекта, что явное взвешивание функции потерь у нейронных сетей. Классы L, R, N распознаются надежно ($\text{recall} \geq 0.98$).




Рис. 5: Нормализованная матрица ошибок ResNet1D.

4.2.4 Сравнение по классу А

Таблица 7 обобщает результаты для наиболее проблематичного класса А — предсердной экстрасистолы.

Таблица 7: Метрики для класса А (предсердная экстрасистола)

Модель	Precision	Recall	F1	Поддержка
1D CNN	0.96	0.92	0.94	509
ResNet1D	0.95	0.88	0.91	509
RandomForest	0.98	0.70	0.82	509

Все модели удовлетворяют требованию $\text{recall}(A) \geq 0.65$ из постановки задачи (раздел 2). CNN превышает этот порог с запасом в 0.27.




Рис. 6: Нормализованная матрица ошибок Random Forest.

4.3 Кривые обучения нейронных сетей

4.3.1 1D CNN




Рис. 7: Кривые потерь (слева) и точности (справа) 1D CNN в процессе обучения. Вертикальная линия соответствует эпохе ранней остановки.

Сеть сходится равномерно: валидационная и обучающая кривые идут вместе — признак отсутствия переобучения. Механизм ReduceLROnPlateau снижает скорость обучения примерно на 10–12 эпохе, что проявляется в характерном «перегибе» кривой

потерь. Ранняя остановка фиксирует лучшие веса до начала возможного переобучения.

4.3.2 ResNet1D




Рис. 8: Кривые потерь и точности ResNet1D.

ResNet1D требует больше эпох для стабилизации по сравнению с CNN, что характерно для более глубоких архитектур: веса нескольких остаточных блоков должны согласоваться друг с другом. Остаточные соединения обеспечивают монотонное снижение потерь без «провалов», характерных для сетей без skip-connections.

4.4 Важность признаков Random Forest

Наиболее информативными оказываются отсчеты в диапазоне x_{95} – x_{115} — непосредственно вблизи R-пика (который находится в позиции x_{100}). Это соответствует крутому подъему и спаду комплекса QRS — наиболее характерному признаку для разделения желудочковых (V) и предсердных (A) аномалий. Отсчеты, соответствующие зубцу T (x_{140} – x_{200}), занимают второй по значимости диапазон: форма T-волны дифференцирует блокады левой и правой ножек (L и R).

4.5 Эксперимент с вейвлет-признаками

Добавление 25 вейвлет-признаков (ДВП db4, 4 уровня) к 240 временным отсчетам не улучшило качество RF: Масго F1 = 0.9479 против 0.9496 (таблица 8).

Разница Масго F1 = -0.0017 находится в пределах статистической погрешности (для выборки 20 005 объектов оценка дисперсии F1-меры невелика, однако систематического улучшения нет). Вероятная причина: случайный лес на 240 сырых отсчетах



Рис. 9: Топ-30 наиболее важных временных точек для Random Forest (оценка MDI). По оси абсцисс — индекс отсчета в окне $[x_0, \dots, x_{239}]$; по оси ординат — нормированная важность.

Таблица 8: Результаты эксперимента с вейвлет-признаками

Модель	Признаков	Accuracy	Macro F1	Weighted F1
RF-Raw	240	0.9848	0.9496	0.9841
RF-Wavelet	265	0.9845	0.9479	0.9837

уже неявно извлекает частотно-временные паттерны — в частности, разность соседних отсчетов кодирует локальную производную, а значит, и высокочастотные компоненты. Агрегатные статистики $(\bar{c}, \sigma, E)$ по каждой подполосе, напротив, теряют позиционную информацию.

Важность групп признаков (рисунок 11) показывает, что суммарный вклад 240 временных точек значительно превышает суммарный вклад всех 25 вейвлет-признаков. Среди вейвлет-подполос наибольший вклад вносят cD_3 и cD_4 , соответствующие диапазону 11–45 Гц, — именно там сосредоточена энергия комплекса QRS и зубцов P, T.




Рис. 10: Сравнение RF на сырых признаках (240 отсчетов) и расширенных вейвлет-признаках (265 признаков).




Рис. 11: Важность групп признаков в RF-Wavelet (слева — суммарно по группам, справа — топ-20 вейвлет-признаков).

5 Устойчивость к шуму и кросс-валидация

5.1 Модели артефактов ЭКГ-сигналов

В реальных условиях холтеровского мониторинга запись ЭКГ неизбежно содержит артефакты различной природы. В работе рассматриваются четыре типа помех, наиболее типичных при амбулаторной регистрации.

Гауссов шум. Моделирует тепловые и квантовые шумы усилительного тракта:

$$\tilde{s}[n] = s[n] + \varepsilon[n], \quad \varepsilon[n] \sim \mathcal{N}(0, \sigma^2). \quad (12)$$

Уровень шума характеризуется параметром σ и нарастает от 0.01 до 0.08 мВ с шагом 0.01.

Дрейф изолинии. Вызван дыхательными движениями и нестабильным контактом электрода с кожей; аппроксимируется медленной синусоидой:

$$\tilde{s}[n] = s[n] + A \sin\left(\frac{2\pi f_0 n}{f_s}\right), \quad f_0 = 0.5 \text{ Гц}. \quad (13)$$

Амплитуда A варьируется от 0.01 до 0.15 мВ с шагом 0.01.

Сетевая помеха 50 Гц. Индуктивная наводка от сети электропитания:

$$\tilde{s}[n] = s[n] + A \sin\left(\frac{2\pi \cdot 50 \cdot n}{f_s}\right). \quad (14)$$

Амплитуда A — от 0.01 до 0.08 мВ.

Мышечный шум (ЭМГ). Сигнал скелетных мышц накладывается на ЭКГ при физической активности; моделируется сглаженным гауссовым шумом:

$$\tilde{s}[n] = s[n] + (A \cdot \varepsilon) * h[n], \quad (15)$$

где $\varepsilon \sim \mathcal{N}(0, 1)$, $h[n]$ — прямоугольный сглаживающий фильтр длиной 5 отсчетов. Амплитуда A — от 0.01 до 0.07 мВ.

5.2 Результаты экспериментов с шумом

Для каждого типа и уровня помехи вычислялись Accuracy и Macro F1 всех трех моделей на тестовой выборке (20 005 объектов). Сводные результаты при максимальных уровнях помех приведены в таблице 9.

Таблица 9: Метрики при максимальных уровнях шума

Тип шума	Уровень	Модель	Accuracy	Macro F1
Гауссов шум	$\sigma=0.08$	CNN	0.9446	0.7869
		ResNet1D	0.8619	0.5888
		RandomForest	0.9703	0.8716
Дрейф изолинии	$A=0.15$	CNN	0.9918	0.9740
		ResNet1D	0.9833	0.9498
		RandomForest	0.9719	0.8901
Сетевая помеха	$A=0.08$	CNN	0.9832	0.9357
		ResNet1D	0.8427	0.6395
		RandomForest	0.9767	0.9114
Мышечный шум	$A=0.07$	CNN	0.9882	0.9603
		ResNet1D	0.9758	0.9228
		RandomForest	0.9830	0.9422

5.2.1 Гауссов шум

При $\sigma = 0.08$ мВ случайный лес сохраняет Macro F1 = 0.872, тогда как CNN опускается до 0.787, а ResNet1D — до 0.589. RF устойчив к случайным аддитивным помехам: пороговые разбиения деревьев не чувствительны к равномерно распределенному по спектру шуму, который усредняется при нахождении оптимального порога. CNN теряет точность сильнее: сверточные фильтры обнаруживают высокочастотные компоненты QRS, которые при высоком σ «маскируются» шумом.

5.2.2 Дрейф изолинии

Наиболее устойчивой к дрейфу оказалась CNN: Macro F1 = 0.974 при $A = 0.15$ мВ — практически без потерь относительно чистых данных. Причина — BatchNorm




Рис. 12: Зависимость Macro F1 от уровня гауссова шума σ .

внутри сверточных блоков нормализует активации по мини-батчу, фактически компенсируя медленное смещение изолинии. ResNet1D также устойчив (0.950). RF деградирует сильнее (0.890): деревья строят пороги по абсолютным значениям отсчетов и чувствительны к сдвигу постоянной составляющей.

5.2.3 Сетевая помеха 50 Гц

Сетевая помеха особенно разрушительна для ResNet1D: Macro F1 падает до 0.640 — потеря 0.31 относительно чистых данных. Слой `AdaptiveAvgPool1d(1)` глобально усредняет карту признаков по временному измерению: периодическая синусоида частотой 50 Гц ($\lambda \approx 7.2$ отсчета) создает регулярные паттерны, которые после усреднения дают ненулевые сдвиги в признаковом пространстве. CNN устойчивее (0.936): два уровня `MaxPool` перед `AdaptiveAvgPool` частично подавляют высокочастотные компоненты. RF стабилен (0.911): пороговые деления нечувствительны к периодическим помехам средней амплитуды.




Рис. 13: Зависимость Macro F1 от амплитуды дрейфа изолинии A .

5.2.4 Мышечный шум

Мышечный шум — наименее критичная помеха для всех трех моделей. CNN лидирует (0.960), RF и ResNet1D показывают близкие результаты (0.942 и 0.923 соответственно). Сглаженная структура ЭМГ-шума (фильтр длиной 5 отсчетов) не разрушает форму QRS-комплекса — именно поэтому все модели сохраняют высокое качество.

5.2.5 Обобщенное сравнение устойчивости

Анализ показывает, что каждая модель имеет свой «профиль устойчивости»:

- **1D CNN** — лучший выбор при дрейфе изолинии и мышечном шуме; BatchNorm обеспечивает нечувствительность к медленным трендам.
- **RandomForest** — наиболее устойчив к гауссову и сетевому шуму; пороговая природа деревьев устойчива к равномерным и периодическим аддитивным помехам.
- **ResNet1D** — наименее устойчив в целом; особенно критична сетевая помеха 50 Гц из-за глобального пулинга.




Рис. 14: Зависимость Macro F1 от амплитуды сетевой помехи 50 Гц.

5.3 Кросс-валидация

5.3.1 Методология

Для оценки стабильности и обобщающей способности моделей проводится пятикратная стратифицированная кросс-валидация ($K = 5$). На каждой итерации k модель обучается на $(K-1)/K$ части данных и оценивается на оставшейся $1/K$ части. Итоговые оценки — среднее и стандартное отклонение метрик по фолдам:

$$\bar{m} \pm \hat{\sigma} = \frac{1}{K} \sum_{k=1}^K m_k \pm \sqrt{\frac{1}{K-1} \sum_{k=1}^K (m_k - \bar{m})^2}. \quad (16)$$

Малое $\hat{\sigma}$ свидетельствует о стабильности модели и отсутствии переобучения на конкретном разбиении.

5.3.2 Результаты по фолдам

Таблица 10 содержит значения метрик для каждого из пяти фолдов.




Рис. 15: Зависимость Macro F1 от амплитуды мышечного шума A .

5.3.3 Сводные оценки

5.3.4 Интерпретация

Результаты кросс-валидации меняют картину относительно однократного разбиения:

Random Forest демонстрирует наилучшую воспроизводимость: $\text{std Macro F1} = 0.0016$ — почти на порядок меньше, чем у CNN. Это объясняется тем, что RF как ансамблевый метод уже внутренне усредняет дисперсию за счет бэггинга и не зависит от случайной инициализации весов.

CNN при однократном обучении показывала $\text{Macro F1} = 0.974$, однако среднее по фолдам $= 0.947 \pm 0.020$ — ниже RF (0.952). Особенно выбивается *фолд 3*: $\text{Macro F1} = 0.919$, что на 0.028 ниже медианы. Это свидетельствует о чувствительности нейронной сети к распределению данных в конкретном разбиении. Вероятная причина — в третьем фолде оказался нетипичный состав редких классов (A , V).

ResNet1D показывает наибольшую нестабильность: $\text{std Accuracy} = 0.072$, $\text{std Macro F1} = 0.053$. Критический фолд 3 — $\text{Accuracy} = 0.783$ — коллапс практически до уровня случайного угадывания для ряда классов. Это следствие нехватки эпох (10 эпох




Рис. 16: Сводная диаграмма устойчивости: Macro F1 при максимальных уровнях всех четырех типов шума.

в CV против 30 при полном обучении): ResNet1D требует больше итераций для согласования остаточных блоков.

Вывод: для задач, где приоритет — воспроизводимость и стабильность, RF предпочтительнее нейронных сетей. Для достижения максимальной точности при достаточном объеме данных и возможности длительного обучения — 1D CNN.

5.4 Сопоставление с требованиями постановки задачи

Таблица 12 содержит итоговую проверку выполнения требований из раздела 2.

RF и CNN удовлетворяют всем четырем требованиям. ResNet1D не выполняет условие на стабильность ($\text{std} = 0.053 > 0.030$), что объясняется недостаточным числом эпох при кросс-валидации. При полном обучении (30 эпох) ResNet1D стабилен.

Таблица 10: Результаты 5-fold кросс-валидации по фолдам

Фолд	RandomForest		CNN		ResNet1D	
	Acc	F1	Acc	F1	Acc	F1
1	0.9853	0.9528	0.9883	0.9634	0.9378	0.8663
2	0.9849	0.9495	0.9800	0.9403	0.9286	0.8553
3	0.9851	0.9506	0.9702	0.9185	0.7830	0.7700
4	0.9857	0.9533	0.9814	0.9459	0.9709	0.9172
5	0.9850	0.9525	0.9898	0.9686	0.9123	0.8391

Таблица 11: Итоговые оценки кросс-валидации (mean $\pm$ std)

Модель	Accuracy	Macro F1
RandomForest	0.9852 ± 0.0003	0.9517 ± 0.0016
CNN	0.9819 ± 0.0078	0.9473 ± 0.0199
ResNet1D	0.9065 ± 0.0723	0.8496 ± 0.0532




Рис. 17: Box-plot результатов 5-fold кросс-валидации. Центральная линия — медиана, ящик — межквартильный диапазон.

Таблица 12: Выполнение требований постановки задачи

Требование	Порог	RF	CNN	ResNet1D
Macro F1 (тест)	≥ 0.90	0.950 ✓	0.974 ✓	0.953 ✓
Recall класса A	≥ 0.65	0.70 ✓	0.92 ✓	0.88 ✓
std F1 (CV)	≤ 0.03	0.002 ✓	0.020 ✓	0.053 ×
Модель сохранена	—	✓	✓	✓

6 Заключение

В настоящей работе исследованы методы автоматической классификации нестационарных биосигналов — электрокардиограмм (ЭКГ) — с использованием алгоритмов машинного обучения. На основе базы данных MIT-BIH Arrhythmia Database ($N = 100\,025$ кардиоциклов пяти классов аритмий) реализован полный конвейер обработки данных, обучены и сравнены три модели, а также проведен анализ их устойчивости к шуму.

Основные результаты

- 1. Разработан конвейер предобработки данных.** Реализовано извлечение кардиоциклов в виде окон длиной 240 отсчетов (100 до и 140 после R-пика), стратифицированное разбиение 80/20, стандартная нормализация для нейронных сетей. Для борьбы с дисбалансом классов (соотношение норма : предсердная экстрасистола $\approx 30:1$) применена взвешенная функция потерь (формула (6)) и стратегия `balanced_subsample` для Random Forest.
- 2. Обучены три модели классификации.** На чистых данных достигнуты следующие результаты (таблица 6):
 - **1D CNN:** Accuracy = 0.9917, Macro F1 = 0.974 — наилучший результат. Recall класса A (предсердная экстрасистола) = 0.92.
 - **ResNet1D:** Accuracy = 0.985, Macro F1 = 0.953.
 - **Random Forest:** Accuracy = 0.985, Macro F1 = 0.950. Recall класса A = 0.70 — существенно ниже нейронных сетей.
- 3. Проведен вейвлет-анализ ЭКГ-сигналов.** С помощью дискретного вейвлет-преобразования (db4, 4 уровня) визуализировано частотно-временное строение кардиоциклов каждого класса. Проверена гипотеза о добавлении вейвлет-признаков к вектору временных отсчетов: расширение пространства признаков с 240 до 265 не улучшило качество Random Forest (Macro F1: 0.9479 против 0.9496), что объясняется способностью ансамбля деревьев неявно улавливать частотно-временные паттерны из сырого сигнала.

4. **Исследована устойчивость к четырем типам помех.** Выявлены характерные профили устойчивости:

- CNN — наилучшая устойчивость к дрейфу изолинии (Macro F1 = 0.974) и мышечному шуму (0.960): BatchNorm нейтрализует медленные тренды.
- Random Forest — наилучшая устойчивость к гауссову (0.872) и сетевому (0.911) шуму: пороговые разбиения нечувствительны к равномерно распределенным и периодическим аддитивным помехам.
- ResNet1D — наименее устойчив к сетевой помехе 50 Гц (Macro F1 = 0.640): глобальный усредняющий пулинг усиливает периодические артефакты в признаковом пространстве.

5. **Достоверность подтверждена кросс-валидацией.** Пятикратная стратифицированная кросс-валидация показала: Random Forest — наиболее стабильная модель (std Macro F1 = 0.002); 1D CNN — средняя стабильность (std = 0.020); ResNet1D — высокая дисперсия по фолдам (std = 0.053) вследствие нехватки эпох обучения при CV-режиме.

Выводы

Все три модели превысили порог Macro F1 ≥ 0.90 на тестовой выборке и порог $\text{recall}(A) \geq 0.65$, что соответствует требованиям постановки задачи (раздел 2).

Если приоритет — *максимальная точность*, рекомендуется **1D CNN**: она лидирует по всем метрикам на чистых данных и устойчива к наиболее распространенным помехам (дрейф изолинии, мышечный шум).

Если приоритет — *воспроизводимость и интерпретируемость*, предпочтительнее **Random Forest**: минимальная дисперсия по фолдам, возможность анализа важности признаков и отсутствие необходимости в дорогостоящем обучении.

Направления дальнейших исследований

- **Вейвлет-шумоподавление как стадия предобработки.** Применение мягкой пороговой обработки коэффициентов ДВП (метод Донохо–Джонстона [13]) перед

подачей сигнала на классификатор может повысить устойчивость всех трех моделей к гауссову и сетевому шуму.

- **Увеличение числа эпох ResNet1D в кросс-валидации.** Полное обучение (30 эпох) дает Macro F1 = 0.953; при CV использовалось лишь 10 эпох — что объясняет нестабильность. Рекомендуется тестировать с 25–30 эпохами.
- **Расширение набора классов.** MIT-BIH содержит более 15 типов аномалий; включение дополнительных классов (например, блокады 1-й и 2-й степени, мерцательная аритмия) приблизит задачу к реальной клинической практике.
- **Персонализированные модели.** Записи разных пациентов существенно различаются по амплитуде и форме ЭКГ; обучение с адаптацией к конкретному пациенту (patient-specific fine-tuning) является перспективным направлением.
- **CWT-признаки для нейронных сетей.** Глубокие сверточные сети уже показали высокое качество при прямой работе с одномерным ЭКГ-сигналом [14]; перспективное расширение — подача скаллограмм непрерывного вейвлет-преобразования (CWT) в двумерную CNN как изображений «частота — время».

Список литературы

- [1] *World Health Organization*. Cardiovascular diseases (CVDs). — [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds)). — 2021.
- [2] *Захарова, Татьяна Валерьевна*. Теория вейвлетов и ее применение в обработке сигналов / Татьяна Валерьевна Захарова, Олег Владимирович Шестаков. — Москва: МастерПринт, 2018.
- [3] Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network / Awni Y. Hannun, Pranav Rajpurkar, Masoumeh Haghpanahi et al. // *Nature Medicine*. — 2019. — Vol. 25, no. 1. — Pp. 65–69.
- [4] *Moody, George B*. The impact of the MIT-BIH Arrhythmia Database / George B. Moody, Roger G. Mark // *IEEE Engineering in Medicine and Biology Magazine*. — 2001. — Vol. 20, no. 3. — Pp. 45–50.
- [5] *Goldberger, Ary L*. PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. — 2000.
- [6] *Association for the Advancement of Medical Instrumentation*. Testing and Reporting Performance Results of Cardiac Rhythm and ST Segment Measurement Algorithms. ANSI/AAMI EC57:1998/(R)2008. — AAMI Standard. — 2012.
- [7] *Breiman, Leo*. Random Forests / Leo Breiman // *Machine Learning*. — 2001. — Vol. 45, no. 1. — Pp. 5–32.
- [8] Gradient-based learning applied to document recognition / Yann LeCun, Léon Bottou, Yoshua Bengio, Patrick Haffner // *Proceedings of the IEEE*. — 1998. — Vol. 86, no. 11. — Pp. 2278–2324.
- [9] *Kingma, Diederik P*. Adam: A Method for Stochastic Optimization / Diederik P. Kingma, Jimmy Ba // *arXiv preprint arXiv:1412.6980*. — 2014.
- [10] *Goodfellow, Ian*. Deep Learning / Ian Goodfellow, Yoshua Bengio, Aaron Courville. — Cambridge, MA: MIT Press, 2016. <http://www.deeplearningbook.org>.

- [11] Deep Residual Learning for Image Recognition / Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2016. — Pp. 770–778.
- [12] *Mallat, Stéphane G.* A theory for multiresolution signal decomposition: the wavelet representation / Stéphane G. Mallat // *IEEE Transactions on Pattern Analysis and Machine Intelligence*. — 1989. — Vol. 11, no. 7. — Pp. 674–693.
- [13] *Donoho, David L.* Ideal spatial adaptation by wavelet shrinkage / David L. Donoho, Iain M. Johnstone // *Biometrika*. — 1994. — Vol. 81, no. 3. — Pp. 425–455.
- [14] A deep convolutional neural network model to classify heartbeats / U. Rajendra Acharya, Shu Lih Oh, Yuki Hagiwara et al. // *Computers in Biology and Medicine*. — 2017. — Vol. 89. — Pp. 389–396.
- [15] *Захарова, Татьяна Валерьевна.* Вейвлет-анализ и его приложения / Татьяна Валерьевна Захарова, Олег Владимирович Шестаков. — 2-е изд., перераб. и доп. edition. — Москва: ИНФРА-М, 2012.
- [16] Cardiologist-Level Arrhythmia Detection with Convolutional Neural Networks / Pranav Rajpurkar, Awni Y. Hannun, Masoumeh Haghpanahi et al. // *arXiv preprint arXiv:1707.01836*. — 2017.
- [17] *Kachuee, Mohammad.* ECG Heartbeat Classification: A Deep Transferable Representation / Mohammad Kachuee, Shayan Fazeli, Majid Sarrafzadeh // 2018 IEEE International Conference on Healthcare Informatics (ICHI). — 2018. — Pp. 443–444.
- [18] SMOTE: Synthetic Minority Over-sampling Technique / Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, W. Philip Kegelmeyer // *Journal of Artificial Intelligence Research*. — 2002. — Vol. 16. — Pp. 321–357.
- [19] Scikit-learn: Machine Learning in Python / Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort et al. // *Journal of Machine Learning Research*. — 2011. — Vol. 12. — Pp. 2825–2830.